

Нейросетевые методы поиска и сегментации объектов в данных современных космических обзоров (eROSITA, ART-XC)


НАУЧНЫЕ РУКОВОДИТЕЛИ:

ГЕРАСИМОВ С.В., МЕЩЕРЯКОВ А.В.


СТУДЕНТ:

НЕМЕШАЕВА АЛИСА, 3 КУРС БАКАЛАВРИАТА ВМК МГУ

Рентгеновские телескопы



eRosita



ART-XC

Рентгеновские телескопы

eROSITA — это рентгеновский телескоп, построенный Институтом внеземной физики Общества Макса Планка (MPE) в Германии.

Количество зеркальных модулей: 7

Энергетический диапазон: 0.3–11 кэВ

ART-XC — телескоп, изготовленный Институтом космических исследований Российской Академии наук совместно с Российским Федеральным ядерным центром (г. Саров, Россия). Также в проекте участвует Центр космических полётов им. Маршалла, НАСА, США.

Количество зеркальных модулей: 7

Энергетический диапазон: 5–30 кэВ

Целью запуска этих телескопов является получение полного обзора неба в рентгеновском диапазоне, что позволит обнаружить новые скопления и сравнить полученные результаты с предыдущими исследованиями.

Актуальность нейросетевых методов для данных с рентгеновских телескопов


Упомянутые выше телескопы были отправлены для исследований только летом этого года. Данные обзоров появятся весной 2020 года, и есть время, чтобы подготовить нужные алгоритмы и изучить данные с предыдущих запусков других телескопов, а также данные симуляций.

Фактически, до этого момента ещё не было попыток применить нейросетевые методы сегментации к данным рентгеновских телескопов, однако можно ожидать, что новые предложенные методы смогут решить многие проблемы существующих алгоритмов.

Актуальность нейросетевых методов для других исследовательских областей


Проблема сегментации облаков точек встречается не только в области исследования данных, полученных с рентгеновских телескопов. В виде облаков точек хранятся данные для многих исследовательских областей, связанных с визуализацией, а также в геоинформационных системах.

С помощью лазеров сканируются здания, после чего информация преобразовывается в трёхмерные объекты, которые потом могут использоваться для других целей. Поэтому результаты, полученные для текущей задачи, могут впоследствии помочь развить аналогичные методы в других исследовательских сферах.



Постановка задачи

Основными задачами являются исследование и разработка нейросетевых алгоритмов для применения на рентгеновских данных телескопов eROSITA и ART-XC.




Особенности целевых данных


В следствие того, что рентгеновские телескопы обрабатывают сигналы только в определённых частотных диапазонах, данные получаются сильно разреженными, и хранить их в виде обычных изображений слишком ресурсозатратно. Поэтому такие данные гораздо удобнее хранить и обрабатывать в виде облаков точек.

Облака точек — наборы вершин в выбранной системе координат. В данном случае для каждой вершины определена не только координата, но и её энергия.

Кроме того, в данных могут появляться искажения и «шум», который нужно отсеивать от основной массы точек.



Постановка задачи




- Требуется изучить примеры данных, которые будут подвергаться сегментации.
- Изучить существующие методы для сегментации космических данных с рентгеновских телескопов.
- Реализовать программы для сегментации с использованием нейросетей и постараться улучшить результаты существующих методов, не использующих нейросети.

Существующие методы сегментации

На данный момент существует несколько пакетов программ, с помощью которых осуществляется сегментирование данных, полученных с рентгеновских телескопов. Одним из них является CIAO (CHANDRA INTERACTIVE ANALYSIS OF OBSERVATIONS), разработанный специально для Космической рентгеновской обсерватории «Чандра».

<https://cxc.harvard.edu/ciao/>



Обзор методов сегментации: основные компоненты CIAO

Базовыми методами, которые предлагает CIAO, являются **celldetect**, **vtpdetect**, и **wavdetect**.

celldetect использует скользящую квадратную клетку с изменяющимся размером для сегментации. Для каждого положения клетки вычисляется значение сигнал/шум, сравнивается со средним значением для фона, и если оно больше, то регистрируется источник, в котором может находиться объект.

vtpdetect использует обнаружение источников тесселяции и перколяции (VTP) Вороного для определения индивидуальных плотностей или потоков для каждого занятого пикселя. Затем инструмент анализирует распределение плотностей для обнаружения объектов.


Обзор методов сегментации: основные компоненты CIAO

wavdetect работает в два этапа. Сначала он обнаруживает возможные исходные пиксели в наборе данных, неоднократно коррелируя их с вейвлет-функциями с различными параметрами. Пиксели с достаточно большими значениями положительной корреляции удаляются из изображения в качестве предполагаемых источников, и последующие корреляции выполняются в том же масштабе. Второй этап генерирует список источников из информации первого этапа для каждого масштаба вейвлета. Этот инструмент разделяет близко расположенные точечные источники и находит расширенные источники, если вейвлетные масштабы выбраны соответствующим образом.

U-net: нейросеть для сегментации изображений

Одной из лучших нейросетевых архитектур для сегментации изображений является **U-net**. Её ключевой особенностью является наличие skip-connection слоёв, таким образом часть слоёв энкодера конкатенируется со слоями декодера, и при сжатии признаков нейросеть теряет меньше информации об изображении, на котором она обучалась.

<https://arxiv.org/pdf/1505.04597.pdf>



Нейросетевые архитектуры для сегментации облаков точек


Если напрямую преобразовывать облака точек в изображения и использовать на них архитектуры для сегментации, точность будет заметно ниже, чем для данных, изначально полученных в качестве изображений.

Были изобретены особые свёртки для облаков точек, которые во многом подобны обычным свёрткам из нейросетей для изображений, но учитывают особенности данных.

Из таких свёрток можно сделать полносвёрточную нейросеть для сегментации, используя архитектуры, которые работали хорошо для задач сегментации изображений, заменяя в них обычные свёртки.

Нейросетевые архитектуры для сегментации облаков точек

Вместо обычных свёрток с размером ядра K , используются специальные преобразования — **иерархические свёртки (χ -свёртки)**, которые концентрируют в одной точке признаки K соседних точек, что по смыслу очень похоже на то, что происходит при использовании обычных свёрток. Из таких свёрток строится архитектура Point-CNN.



<https://arxiv.org/pdf/1801.07791.pdf>

Как работают χ -свёртки

На вход свёртка получает 4 объекта:

- K (размер ядра свёртки, от этого числа зависит количество тренируемых параметров),
- p (точка-образец, которая будет агрегировать признаки своих соседей),
- P (матрица параметров K соседних точек, размерность $K \times \dim L$),
- F (матрица признаков для обучения, размерность $K \times C_1$).

L – пространство точек предыдущего слоя. Первый слой имеет размерность 3, поэтому размерность матрицы P для первой свёртки будет $K \times 3$.

Выход свёртки:

F_p - проекция входных параметров на точку p .

Как работают χ -свёртки

- 1) Переводим \mathbf{P} в локальную систему координат p .
- 2) Переводим \mathbf{P}' в пространство размерности δ с помощью многослойного персептрона.
- 3) Конкатенируем \mathbf{F}_δ и \mathbf{F} в матрицу \mathbf{F}_* размера $K \times (C_\delta + C_1)$
- 4) Преобразуем \mathbf{P}' с помощью другого многослойного персептрона.
- 5) Перемножаем матрицы χ и \mathbf{F}_* .
- 6) Обычная свёртка для матрицы \mathbf{F}_* с ядром \mathbf{K} .

C_1, C_δ — количество каналов в промежуточных матрицах.

C_1 означает количество фильтров для первой χ -свёртки, а C_δ выбирают как $\frac{1}{4}$ от C_1 , хотя эти значения можно менять и смотреть, как это повлияет на общее качество результатов.

ALGORITHM 1: χ -Conv Operator

Input : $\mathbf{K}, p, \mathbf{P}, \mathbf{F}$

Output : \mathbf{F}_p

- 1: $\mathbf{P}' \leftarrow \mathbf{P} - p$
 - 2: $\mathbf{F}_\delta \leftarrow MLP_\delta(\mathbf{P}')$
 - 3: $\mathbf{F}_* \leftarrow [\mathbf{F}_\delta, \mathbf{F}]$
 - 4: $\chi \leftarrow MLP(\mathbf{P}')$
 - 5: $\mathbf{F}_\chi \leftarrow \chi \times \mathbf{F}_*$
 - 6: $\mathbf{F}_p \leftarrow \text{Conv}(\mathbf{K}, \mathbf{F}_\chi)$
-

Метрики


Чаще всего в области сегментации облаков точек используются метрики **IoU** (Intersection over union) и её модификации, а также классическая точность **Overall Accuracy** (отношение числа верно сегментированных точек к неверно сегментированным), **mean per-class Accuracy** (средняя точность для каждого класса).

IoU считается для ground truth значений и для предсказанных как отношение количества верно опознанных точек к общему числу точек, обозначенных как верные.

IoU можно посчитать для каждого класса, а в качестве результата использовать среднее между ними, получится **mpIoU** (mean per class IoU).

ОА позволяет оценить общее количество верных ответов, в то время как IoU оценивает и количество отличных от истинного значения результатов.

IoU очень часто используется как метрика для оценки методов компьютерного зрения.

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$


Текущие результаты

На данный момент на основе архитектуры U-net был создан образец нейросети, созданной при использовании библиотеки PyTorch, поэтому уже можно проверить, насколько такая архитектура эффективна для поставленной задачи.

План дальнейшей работы

Подробно изучить синтезированные и настоящие данные. Исследовать закономерности, возникающие в этих данных.

Реализовать упомянутые архитектуры и проверить их работоспособность на имеющихся данных.

Рассмотреть способы улучшения архитектур и методы предварительной обработки входных данных.